

PROPOSAL RISET
“DETEKSI KEMATANGAN SAWIT DENGAN METODE XCEPTION DAN VGG16
DENGAN AUGMENTASI DATA”



Muhammad Rafly Amartharizqi

21081010311

Dosen Pengampu :

Dr. Basuki Rahmat, S.Si, MT

PROGRAM STUDI INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR
2024

BAB I

PENDAHULUAN

1.1. Latar Belakang

Sektor perkebunan menjadi andalan perekonomian Indonesia, memberikan kontribusi sebesar 96,86% dari total ekspor pertanian, dengan 73,83% di antaranya berasal dari kelapa sawit (Fevriera and Safara Devi 2023). Hal ini menjadikan kelapa sawit memiliki peranan yang sangat penting bagi Indonesia, terutama sebagai negara penghasil dan pengekspor minyak kelapa sawit terbesar di dunia (Siswanto, Lubis, and Akoeb 2020). Komoditas ini memproduksi Crude Palm Oil (CPO), yang nantinya digunakan untuk memproduksi kosmetik, bahan baku pangan, dan bahan bakar biodiesel. Menurut Badan Pusat Statistik pada tahun 2023, terdapat 47 juta ton CPO yang dihasilkan dari kelapa sawit (Indonesia 2024). Produksi CPO dipengaruhi oleh dua faktor utama: tingkat ekstraksi minyak di pabrik kelapa sawit dan kandungan minyak yang terdapat pada tandan buah segar (Murgianto et al. 2021). Buah kelapa sawit yang matang optimal merupakan syarat utama untuk menghasilkan CPO berkualitas tinggi. Indikator kematangan buah dapat dilihat dari perubahan warnanya menjadi kuning kemerahan (Murgianto et al. 2021). Tingkat kematangan memiliki hubungan linear dengan hasil CPO—semakin matang buahnya, semakin tinggi pula rendemen CPO yang diperoleh. Selain itu, fase kematangan buah juga berperan penting dalam menentukan konsentrasi senyawa-senyawa bermanfaat seperti tokol dan beta karoten (Akbar, Wibowo, and Santoso 2023).

Identifikasi tingkat kematangan kelapa sawit saat ini masih bertumpu pada pengamatan visual oleh pekerja. Tantangan timbul dalam membedakan beberapa fase kematangan yang memiliki ciri-ciri mirip. Hal ini berpotensi mempengaruhi optimalisasi hasil produksi kelapa sawit secara keseluruhan. Efisiensi produksi dan kualitas produk dapat dipertahankan melalui sistem klasifikasi yang tepat dalam mengelompokkan hasil kelapa sawit berdasarkan standar mutunya. Strategi peningkatan kualitas produk dapat dilakukan melalui penerapan teknologi Machine Learning menggunakan algoritma Xception dan VGG16, yang memungkinkan pengelompokan produk kelapa sawit secara lebih efektif.

Algoritma Xception (Extreme version of Inception) adalah salah satu metode yang dikembangkan dalam bidang deep learning (Masaugi 2024). Penelitian yang dilakukan oleh François Chollet menunjukkan bahwa model Xception memiliki akurasi tertinggi sebesar 94,5% pada tugas klasifikasi (Avery et al. 2014). Penelitian lain yang menggunakan Xception untuk klasifikasi citra tanaman minyak atsiri menunjukkan bahwa model dapat mencapai akurasi pelatihan sebesar 93% dan validasi sebesar 77% hanya dengan 5 epoch (Carnegie et al. 2022).

Di sisi lain, algoritma VGG16, yang dikembangkan oleh Visual Geometry Group, merupakan model berbasis CNN (Convolutional Neural Network) dengan 16 lapisan yang dirancang untuk klasifikasi citra (Thakur 2024). VGG16 telah terbukti efektif dalam berbagai tugas klasifikasi citra, terutama karena arsitekturnya yang sederhana namun sangat dalam. Dalam studi sebelumnya, VGG16 mampu mencapai akurasi tinggi pada dataset citra berukuran besar dengan kinerja yang konsisten.

Kombinasi arsitektur VGG16 dengan teknik augmentasi data dapat membantu meningkatkan generalisasi model, terutama pada dataset dengan distribusi kelas yang tidak seimbang .

Pada saat pelatihan data, diperlukan augmentasi data untuk menghindari masalah overfitting (Rizki et al. 2023). Augmentasi bertujuan untuk meningkatkan variasi data sekaligus memperkuat kemampuan generalisasi model deep learning (Chan Uswatun, Angkin 2023). Dalam dataset citra yang telah dikumpulkan, ditemukan ketidakseimbangan antara kelas matang dan belum matang.

Berdasarkan latar belakang tersebut, algoritma Xception dan VGG16 dipilih untuk klasifikasi tingkat kematangan buah kelapa sawit karena kemampuannya yang telah terbukti dalam mengatasi tugas klasifikasi citra dengan tingkat akurasi yang tinggi. Penelitian ini bertujuan untuk mengembangkan model klasifikasi yang efektif dalam mengidentifikasi kematangan buah kelapa sawit, yang pada gilirannya dapat meningkatkan efisiensi dan kualitas produksi CPO.

Dalam penelitian ini, data citra buah kelapa sawit yang telah dikumpulkan akan menjalani proses pengolahan awal, termasuk augmentasi untuk mengatasi masalah ketidakseimbangan kelas. Proses augmentasi ini bertujuan untuk memperluas variasi data tanpa perlu mengumpulkan data tambahan secara fisik. Setelah itu, model Xception dan VGG16 akan dilatih menggunakan dataset tersebut, dengan penekanan pada optimalisasi parameter model guna meningkatkan akurasi klasifikasi.

Diharapkan hasil dari penelitian ini akan menghasilkan model yang mampu secara otomatis mengelompokkan buah kelapa sawit ke dalam kategori matang dan belum matang dengan tingkat akurasi yang tinggi. Penerapan model ini tidak hanya akan membantu pekerja dalam mengidentifikasi kematangan buah dengan lebih konsisten, tetapi juga berkontribusi pada peningkatan produktivitas dan kualitas industri kelapa sawit di Indonesia.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana membangun model klasifikasi menggunakan algoritma Xception dan VGG16 untuk mendeteksi tingkat kematangan buah kelapa sawit?
2. Bagaimana penerapan augmentasi data untuk meningkatkan performa model pada dataset dengan ketidakseimbangan kelas?
3. Seberapa efektif algoritma Xception dibandingkan dengan VGG16 dalam melakukan klasifikasi tingkat kematangan buah kelapa sawit?

1.3. Tujuan Penelitian

Penelitian ini bertujuan untuk:

1. Mengembangkan model klasifikasi yang efektif untuk mendeteksi tingkat kematangan buah kelapa sawit menggunakan algoritma Xception dan VGG16.
2. Menerapkan augmentasi data untuk meningkatkan variasi dataset dan mengatasi masalah ketidakseimbangan kelas.
3. Membandingkan performa algoritma Xception dan VGG16 berdasarkan akurasi klasifikasi tingkat kematangan buah kelapa sawit.

1.4. Manfaat Penelitian

Penelitian ini diharapkan memberikan manfaat sebagai berikut:

1. Bagi Industri Perkebunan: Memberikan solusi teknologi yang dapat meningkatkan efisiensi identifikasi kematangan buah kelapa sawit secara otomatis, sehingga mendukung peningkatan kualitas CPO.
2. Bagi Dunia Akademik: Menjadi referensi dalam penelitian klasifikasi citra menggunakan algoritma Xception dan VGG16 serta augmentasi data.
3. Bagi Pekerja Perkebunan: Mengurangi kesalahan pengamatan visual yang sering terjadi dalam identifikasi kematangan buah kelapa sawit.

1.5. Batasan Masalah

Untuk menjaga fokus penelitian, terdapat beberapa batasan dalam penelitian ini, yaitu:

1. Data citra yang digunakan dalam penelitian ini hanya mencakup buah kelapa sawit dengan kategori matang dan belum matang.
2. Algoritma yang digunakan dalam penelitian ini terbatas pada Xception dan VGG16.
3. Dataset yang digunakan akan melalui proses augmentasi untuk mengatasi ketidakseimbangan kelas, tanpa menambah data secara fisik.
4. Penelitian ini hanya berfokus pada evaluasi performa model dalam hal akurasi klasifikasi tanpa mempertimbangkan aspek lain seperti waktu inferensi atau efisiensi komputasi.

Bab II

Tinjauan Pustaka

2.1 Landasan Teori

2.1.1 Kelapa Sawit

Kelapa sawit merupakan salah satu komoditas perkebunan yang memiliki peran strategis dalam perekonomian, terutama di negara-negara tropis seperti Indonesia dan Malaysia. Sebagai produsen utama minyak sawit dunia, Indonesia menjadikan kelapa sawit sebagai salah satu sektor unggulan yang berkontribusi besar terhadap pendapatan nasional dan ekspor. Buah kelapa sawit adalah bahan utama dalam pembuatan minyak sawit mentah (crude palm oil/CPO), yang kemudian diolah menjadi berbagai produk seperti minyak goreng, margarin, sabun, hingga biodiesel. Dengan meningkatnya kebutuhan minyak nabati di pasar global, kelapa sawit menjadi komoditas yang sangat kompetitif dibandingkan dengan minyak nabati lainnya seperti minyak kedelai atau minyak zaitun, berkat produktivitasnya yang tinggi dan biaya produksinya yang relatif rendah.

Dalam proses pengolahannya, salah satu aspek krusial yang menentukan kualitas dan kuantitas minyak yang dihasilkan adalah tingkat kematangan buah kelapa sawit. Buah yang dipanen terlalu muda atau terlalu matang dapat menghasilkan minyak dengan kualitas yang rendah atau volume yang lebih sedikit. Oleh karena itu, identifikasi tingkat kematangan buah kelapa sawit menjadi fokus penting dalam industri ini. Proses identifikasi seringkali dilakukan secara manual, yang memerlukan keahlian tinggi dari tenaga kerja, tetapi metode ini tidak hanya memakan waktu, melainkan juga rentan terhadap kesalahan manusia. Seiring dengan perkembangan teknologi, penerapan kecerdasan buatan, khususnya deep learning, menawarkan solusi yang lebih efisien untuk mengotomasi proses identifikasi kematangan buah kelapa sawit, sehingga dapat meningkatkan akurasi dan efisiensi operasional industri.

2.1.2 Dataset

Dataset yang digunakan dalam penelitian ini berisi koleksi gambar buah kelapa sawit yang dikelompokkan ke dalam dua kategori utama, yaitu matang dan mentah. Dataset ini bersumber dari <https://www.kaggle.com/datasets/ahmadfathan/kematangansawit>. Dataset ini dirancang untuk mendukung pengembangan model klasifikasi menggunakan teknik deep learning, khususnya CNN. Gambar dalam dataset mencakup variasi dari berbagai sudut pengambilan, kondisi pencahayaan, dan latar belakang untuk memastikan keberagaman data. Keberagaman ini bertujuan untuk meningkatkan kemampuan model dalam melakukan generalisasi, sehingga dapat mengenali tingkat kematangan buah kelapa sawit secara akurat meskipun data uji memiliki karakteristik yang berbeda dari data latih. Proses labeling dataset dilakukan secara manual untuk memastikan keakuratan kategori. Gambar dalam kategori matang mencerminkan buah dengan warna merah kekuningan, sedangkan kategori mentah diidentifikasi berwarna hitam.

2.1.3 Augmentasi

Augmentasi data merupakan teknik penting dalam pengolahan data yang bertujuan untuk meningkatkan variasi dataset pelatihan tanpa harus mengumpulkan lebih banyak data baru. Proses ini dilakukan dengan cara memanipulasi gambar asli sehingga menghasilkan berbagai

versi modifikasi dari gambar tersebut, yang tetap mempertahankan label aslinya. Dalam penelitian ini, beberapa teknik augmentasi digunakan untuk memperkaya dataset, antara lain rotasi, flipping horizontal dan vertikal, perubahan kecerahan, dan zoom in maupun zoom out. Rotasi dilakukan untuk mensimulasikan gambar buah kelapa sawit yang diambil dari sudut yang berbeda, sehingga model dapat belajar mengenali pola visual dari berbagai orientasi. Flipping, baik secara horizontal maupun vertikal, membantu memperluas perspektif model dalam memahami simetri dan variasi posisi objek.

Perubahan kecerahan digunakan untuk mencerminkan kondisi pencahayaan yang beragam, seperti gambar yang diambil di bawah sinar matahari terik atau dalam kondisi teduh. Teknik zoom, baik memperbesar (zoom in) maupun memperkecil (zoom out), memungkinkan model untuk belajar mengenali objek dengan skala yang berbeda, seperti gambar buah kelapa sawit yang diambil dari jarak dekat maupun jauh. Penerapan augmentasi ini bertujuan utama untuk mencegah overfitting, yaitu kondisi di mana model terlalu terlatih pada data pelatihan sehingga kurang mampu mengenali data baru. Selain itu, augmentasi membantu model meningkatkan generalisasi dan performanya dalam tugas klasifikasi tingkat kematangan buah kelapa sawit, terutama pada dataset yang memiliki keterbatasan jumlah gambar. Dengan augmentasi, dataset yang kecil dapat diperluas secara virtual, memungkinkan model belajar dari lebih banyak variasi data tanpa harus mengumpulkan gambar tambahan secara manual.

2.1.4 Data Preprocessing

$$Rescale = \frac{piksel}{255}$$

Gambar 2 1 Rumus Rescale

Data preprocessing merupakan tahap penting dalam persiapan dataset sebelum digunakan untuk melatih model convolutional neural network (CNN). Langkah-langkah preprocessing bertujuan untuk memastikan data memiliki format yang konsisten, terstandarisasi, dan kompatibel dengan arsitektur model yang digunakan. Salah satu langkah utama dalam preprocessing adalah normalisasi piksel gambar ke rentang [0, 1]. Proses ini dilakukan dengan membagi nilai piksel, yang biasanya berada pada rentang [0, 255], dengan nilai maksimum 255. Normalisasi ini tidak hanya mempercepat konvergensi selama pelatihan model, tetapi juga membantu meningkatkan stabilitas numerik dalam perhitungan parameter model.

Selain normalisasi, pengubahan ukuran gambar adalah langkah krusial lainnya. Gambar dalam dataset diubah ukurannya agar sesuai dengan dimensi input yang diterima oleh model CNN, misalnya 224x224 piksel untuk arsitektur seperti Xception atau VGG16. Penyesuaian ukuran ini memastikan bahwa semua data memiliki dimensi seragam, yang penting untuk menjaga konsistensi selama pelatihan. Untuk mempertahankan aspek rasio gambar asli dan menghindari distorsi, teknik resampling seperti bilinear interpolation atau bicubic interpolation sering digunakan.

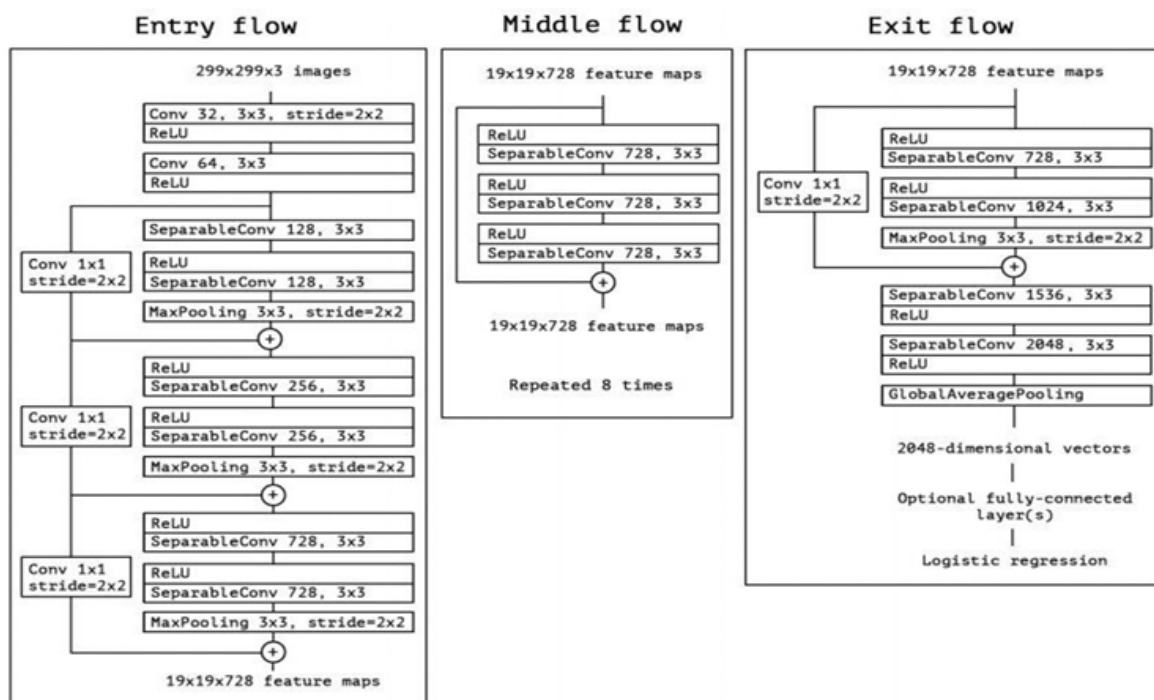
Langkah terakhir dalam preprocessing adalah konversi label menjadi format one-hot encoding. Dalam kasus klasifikasi dua kelas, seperti tingkat kematangan buah kelapa sawit (matang dan mentah), label dikonversi ke vektor biner. Sebagai contoh, label "matang" direpresentasikan sebagai [1, 0], sementara "mentah" sebagai [0, 1]. Representasi ini tidak hanya memudahkan model dalam memahami kategori output tetapi juga mengurangi kemungkinan terjadinya bias yang disebabkan oleh perbedaan nilai numerik antara label. Dengan melakukan preprocessing

secara menyeluruh, dataset menjadi lebih siap untuk diproses oleh model CNN, memungkinkan pelatihan berlangsung dengan lebih efisien dan hasil yang lebih akurat.

2.1.5 Xception

Xception (Extreme Inception) adalah salah satu arsitektur convolutional neural network (CNN) modern yang dikembangkan untuk meningkatkan efisiensi dan akurasi dalam tugas deteksi dan klasifikasi gambar. Model ini merupakan pengembangan dari arsitektur Inception yang populer, dengan memperkenalkan konsep *depthwise separable convolution*, yang membagi proses convolution menjadi dua tahap: depthwise convolution untuk memfilter informasi spasial dan pointwise convolution untuk memadukan informasi tersebut. Pendekatan ini secara signifikan mengurangi jumlah parameter dan komputasi dibandingkan convolution tradisional, tanpa mengorbankan performa model. Karena efisiensinya, Xception telah banyak digunakan dalam berbagai aplikasi pengenalan pola, termasuk klasifikasi gambar dan deteksi objek.

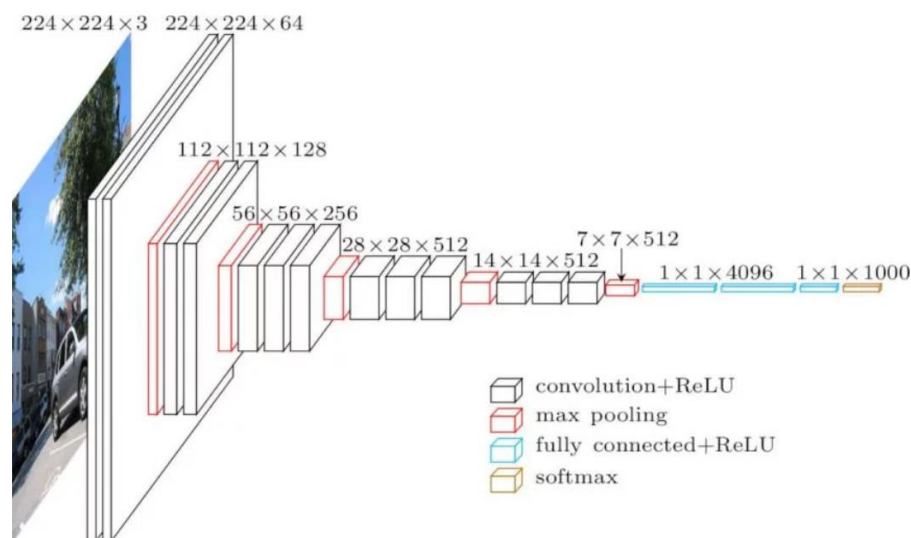
Keunggulan utama Xception terletak pada kemampuan arsitekturnya untuk menangkap fitur spasial dan struktural gambar dengan lebih efektif. Model ini menggunakan stacking dari depthwise separable convolution dalam jumlah yang lebih banyak dibandingkan arsitektur sebelumnya, sehingga dapat menggali fitur yang lebih dalam dan kompleks dari data gambar. Dalam konteks penelitian ini, Xception dipilih untuk mengklasifikasikan tingkat kematangan buah kelapa sawit, karena kemampuannya untuk menangani data gambar dengan kompleksitas tinggi dan menghasilkan akurasi yang lebih baik. Dengan menggunakan dataset gambar kelapa sawit yang telah diproses, Xception diharapkan dapat membedakan buah matang dan mentah dengan presisi yang tinggi, mendukung efisiensi proses identifikasi kematangan secara otomatis dalam industri perkebunan.



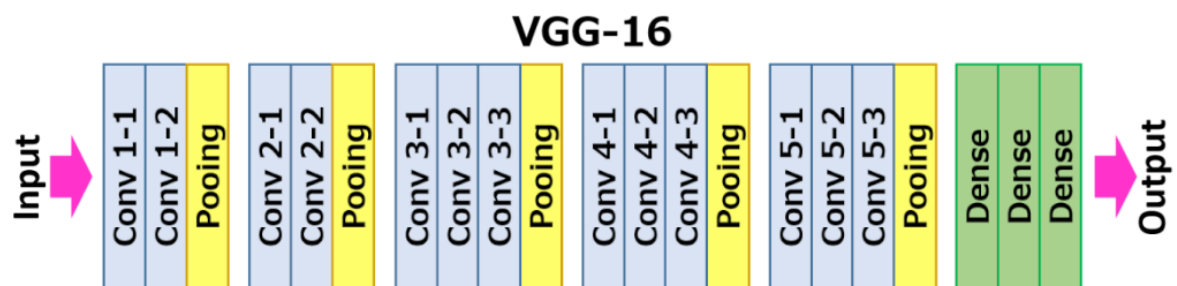
Gambar 2.2 Layer pada Xception

Gambar 2.2 memperlihatkan secara rinci lapisan-lapisan yang membentuk arsitektur dari model Xception. Model ini dirancang untuk menerima input berukuran 299x299 piksel. Arsitektur Xception memiliki 36 lapisan konvolusi yang tersusun dengan tujuan utama untuk mengekstraksi fitur-fitur penting dari data input. Setiap lapisan konvolusi dalam arsitektur ini berperan dalam mengidentifikasi pola-pola kompleks pada gambar, yang kemudian digunakan untuk proses klasifikasi atau deteksi objek. Xception mengimplementasikan konsep kedalaman jaringan yang cukup tinggi dengan menggunakan lapisan-lapisan konvolusi yang saling terhubung untuk membangun representasi fitur yang lebih mendalam dan akurat. Berikut adalah penjelasan lebih lanjut mengenai lapisan-lapisan yang terdapat dalam algoritma Xception.

2.1.6 VGG16



Gambar 3. 1 Arsitektur VGG16 (1)



Gambar 3. 2 Arsitektur VGG16 (2)

VGG16 adalah salah satu model convolutional neural network (CNN) yang paling populer dan banyak digunakan dalam bidang computer vision. Model ini dikembangkan oleh tim Visual Geometry Group (VGG) di Universitas Oxford, dengan tujuan untuk menyederhanakan desain arsitektur CNN tanpa mengorbankan performa. VGG16 mendapatkan namanya karena memiliki 16 lapisan yang terdiri dari kombinasi convolutional layers, pooling layers, dan fully connected layers. Salah satu karakteristik utama dari VGG16 adalah penggunaan filter dengan ukuran kecil (3x3) dalam setiap lapisan convolutional, yang memungkinkan model untuk menangkap detail spasial dari gambar secara lebih mendalam. Dengan pendekatan ini, VGG16

dapat belajar fitur tingkat rendah hingga tinggi secara bertahap, dari tepi dan tekstur hingga pola kompleks dalam gambar.

Pada gambar 3,1 gambar tersebut merupakan arsitektur dari VGG16. Input untuk lapisan konvolusi pertama (cov1) adalah gambar RGB dengan ukuran tetap 224 x 224 piksel. Gambar ini kemudian diproses melalui serangkaian lapisan konvolusi, menggunakan filter dengan ukuran field penerimaan yang sangat kecil, yaitu 3×3 (yang cukup kecil untuk menangkap konsep kiri/kanan, atas/bawah, dan tengah). Dalam beberapa konfigurasi, juga digunakan filter konvolusi 1×1, yang dapat dianggap sebagai transformasi linier dari saluran input, diikuti oleh non-linearitas. Langkah konvolusi ditetapkan 1 piksel, dan padding spasial pada input lapisan konvolusi dilakukan sedemikian rupa agar resolusi spasial tetap terjaga setelah proses konvolusi, dengan padding 1 piksel untuk lapisan konvolusi 3×3. Proses pooling spasial dilakukan melalui lima lapisan max-pooling yang mengikuti beberapa lapisan konvolusi (tidak semua lapisan konvolusi diikuti oleh max-pooling). Max-pooling dilakukan pada jendela 2×2 piksel dengan langkah 2 (Hassan 2018).

Tiga lapisan Fully-Connected (FC) ditempatkan setelah lapisan konvolusi, dengan kedalaman yang bervariasi pada arsitektur yang berbeda. Dua lapisan pertama memiliki 4096 saluran masing-masing, sementara lapisan ketiga bertugas untuk klasifikasi ILSVRC dengan 1000 saluran (satu saluran untuk setiap kelas). Lapisan terakhir adalah lapisan softmax. Konfigurasi lapisan fully connected ini konsisten di semua jaringan.

Semua lapisan tersembunyi dilengkapi dengan non-linearitas ReLU (Rectified Linear Unit). Selain itu, penting untuk dicatat bahwa sebagian besar jaringan (kecuali satu) tidak menggunakan Local Response Normalization (LRN), karena normalisasi ini tidak meningkatkan kinerja pada dataset ILSVRC, dan justru dapat meningkatkan penggunaan memori dan waktu komputasi.

Keunggulan VGG16 terletak pada arsitektur yang sederhana namun sangat efektif, menjadikannya model yang mudah diterapkan di berbagai aplikasi seperti klasifikasi gambar, deteksi objek, dan segmentasi. Dalam penelitian ini, VGG16 digunakan sebagai model pembanding untuk mengevaluasi kinerja Xception dalam klasifikasi tingkat kematangan buah kelapa sawit. VGG16 dipilih karena stabilitas dan keandalannya dalam menghasilkan akurasi tinggi pada dataset gambar dengan ukuran relatif kecil hingga menengah. Meskipun memiliki jumlah parameter yang lebih besar dibandingkan Xception, struktur VGG16 tetap memberikan standar yang baik untuk mengukur kemampuan model lain, termasuk dalam hal presisi, generalisasi, dan waktu komputasi. Dengan membandingkan hasil yang diperoleh dari VGG16 dan Xception, penelitian ini dapat memberikan wawasan lebih mendalam tentang keunggulan masing-masing model dalam mengklasifikasikan tingkat kematangan buah kelapa sawit.

2.1.7 Hyperparameter Optimizer

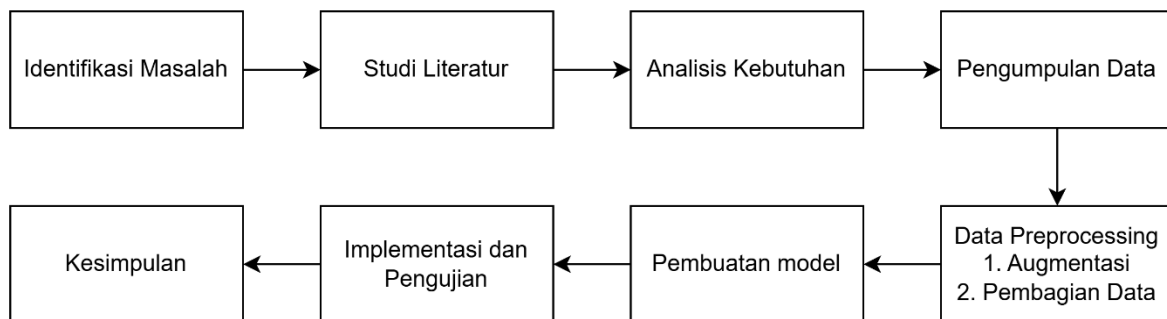
Hyperparameter optimizer adalah salah satu aspek penting dalam pelatihan model deep learning, yang bertujuan untuk menemukan kombinasi optimal dari hyperparameter agar model dapat mencapai performa terbaiknya. Hyperparameter adalah parameter yang tidak diperbarui selama proses pelatihan, tetapi memiliki pengaruh signifikan terhadap hasil akhir model. Contoh hyperparameter meliputi learning rate, batch size, jumlah epoch, dan jenis optimizer yang digunakan. Dalam konteks deep learning, optimizer mengacu pada algoritma yang bertugas mengatur cara pembaruan bobot selama proses pelatihan berdasarkan gradien loss function.

Beberapa metode populer untuk optimasi hyperparameter termasuk pencarian grid (grid search), pencarian acak (random search), dan teknik yang lebih canggih seperti Bayesian Optimization dan Hyperband. Dalam penelitian ini, optimizer Adam (Adaptive Moment Estimation) digunakan sebagai hyperparameter optimizer utama. Adam adalah algoritma yang menggabungkan keunggulan dari metode Momentum dan RMSProp, yang mampu menyesuaikan learning rate secara adaptif untuk setiap parameter. Adam memiliki kelebihan dalam konvergensi yang lebih cepat dan stabil dibandingkan optimizer tradisional seperti SGD (Stochastic Gradient Descent). Dengan menggunakan Adam, model diharapkan dapat mencapai keseimbangan optimal antara kecepatan pelatihan dan akurasi hasil, terutama pada dataset yang kompleks seperti gambar buah kelapa sawit.

BAB III DESAIN DAN IMPLEMENTASI SISTEM

3.1 Metodologi Penelitian

Pada metodologi penelitian ini peneliti akan menguraikan langkah-langkah dan proses penelitian yang dilakukan dalam studi ini. Proses penelitian dimulai dengan melakukan studi literatur, dilanjutkan dengan analisis kebutuhan, pengumpulan data, preprocessing data meliputi augmentasi data dan pembagian data, pembuatan model, implementasi dan pengujian dan diakhiri dengan pembuatan kesimpulan. Tahapan-tahapan ini dirancang untuk memastikan bahwa penelitian dilaksanakan secara sistematis dan terstruktur.



Gambar 3. 3 Metodologi Penelitian

3.1.1 Identifikasi Masalah

Tahap pertama dalam proses penelitian ini adalah identifikasi masalah. Pada tahap ini, peneliti mengamati dan menganalisis permasalahan utama yang dihadapi. Identifikasi ini mencakup penentuan tujuan utama penelitian, relevansi permasalahan dengan kebutuhan, dan manfaat yang diharapkan dari solusi yang akan dikembangkan. Langkah ini penting untuk memastikan bahwa penelitian memiliki arah yang jelas dan dapat menjawab permasalahan secara efektif.

3.1.2 Studi Literatur

Setelah masalah teridentifikasi, dilakukan studi literatur untuk mengkaji penelitian-penelitian terdahulu yang relevan. Studi ini bertujuan untuk memahami konsep-konsep teori, metode yang telah digunakan, serta teknologi yang tersedia. Dengan mempelajari literatur, peneliti mendapatkan landasan yang kuat untuk

mengembangkan solusi baru dan memastikan bahwa penelitian memiliki kontribusi ilmiah yang signifikan.

3.1.3 Analisis Kebutuhan

Tahap berikutnya adalah analisis kebutuhan, di mana peneliti mendefinisikan secara mendalam kebutuhan sistem atau model yang akan dibuat. Analisis ini mencakup pengumpulan spesifikasi teknis, identifikasi sumber daya yang diperlukan, dan penentuan hasil yang diinginkan. Hasil dari tahap ini menjadi panduan dalam proses pengembangan model di tahap selanjutnya.

3.1.4 Pengumpulan Data

Pada tahap ini, dilakukan pengumpulan data yang diperlukan untuk mendukung penelitian. Data yang dikumpulkan harus relevan dengan permasalahan dan berkualitas tinggi agar dapat digunakan dalam pengembangan model. Pengumpulan data bisa dilakukan melalui berbagai metode, seperti survei, eksperimen, atau penggunaan dataset yang sudah tersedia.

3.1.5 Data Preprocessing

Tahap ini bertujuan untuk mempersiapkan data agar siap digunakan dalam proses pembuatan model. Data preprocessing mencakup langkah-langkah seperti augmentasi data, yang bertujuan untuk memperbanyak variasi data melalui teknik tertentu, dan pembagian data, di mana dataset dibagi menjadi data latih dan data uji. Langkah ini memastikan bahwa data yang digunakan dapat memberikan hasil yang akurat dan andal.

3.1.6 Pembuatan Model

Setelah data siap, tahap selanjutnya adalah pembuatan model. Pada tahap ini, peneliti merancang dan mengembangkan model yang dapat menyelesaikan permasalahan yang telah diidentifikasi. Pembuatan model mencakup pemilihan metode, algoritma, serta implementasi teknis yang sesuai dengan kebutuhan yang telah dianalisis sebelumnya.

3.1.7 Implementasi dan Pengujian

Tahap implementasi dan pengujian bertujuan untuk memastikan bahwa model yang telah dibuat bekerja sesuai ekspektasi. Model diuji menggunakan data uji untuk mengevaluasi performa dan akurasi. Hasil dari pengujian ini digunakan untuk memperbaiki model dan memastikan bahwa model dapat diterapkan pada skenario nyata.

3.1.8 Kesimpulan

Tahap akhir dari proses penelitian adalah penyusunan kesimpulan. Kesimpulan ini mencakup ringkasan hasil penelitian, evaluasi terhadap kinerja model, serta rekomendasi untuk pengembangan lebih lanjut. Tahap ini juga menjelaskan kontribusi penelitian terhadap bidang yang dikaji dan potensi penerapannya dalam konteks yang lebih luas.

3.2 Augmentasi

Untuk memperkaya dan meningkatkan variasi data yang digunakan dalam penelitian, dilakukan proses augmentasi pada dataset citra kelapa sawit. Data yang digunakan terdiri dari dua kategori utama, yaitu kelapa sawit matang dan belum matang. Augmentasi ini bertujuan untuk menghasilkan variasi data yang lebih beragam guna meningkatkan performa model pembelajaran mesin yang akan dibangun. Proses augmentasi dilakukan dengan menggunakan berbagai teknik transformasi sederhana, seperti flip vertikal, flip horizontal, rotasi, perubahan kecerahan (brightness), dan perubahan kontras (contrast) pada citra asli. Teknik ini mampu memperluas variasi posisi, orientasi, dan kondisi visual gambar sehingga model dapat lebih adaptif terhadap kondisi nyata. Dengan augmentasi, data menjadi lebih representatif terhadap berbagai situasi lapangan, seperti perbedaan sudut pengambilan gambar, perubahan pencahayaan, dan variasi kondisi citra.

Proses augmentasi ini diimplementasikan secara otomatis menggunakan Google Colab, memanfaatkan bahasa pemrograman Python dan library Augmentor. Library ini dipilih karena kemampuannya yang fleksibel dalam menangani berbagai jenis transformasi pada gambar secara efisien. Dalam penelitian ini, proses augmentasi menghasilkan sebanyak 500 gambar sawit matang dan 500 gambar sawit belum matang, dengan variasi yang dihasilkan dari kombinasi teknik augmentasi yang telah disebutkan. Total data augmentasi yang diperoleh mencapai 1000 citra. Penambahan data ini diharapkan dapat meningkatkan akurasi model dalam mengenali perbedaan antara sawit matang dan belum matang, sekaligus mengurangi risiko overfitting akibat jumlah data yang terlalu sedikit. Dengan adanya beragam jenis augmentasi, model memiliki kesempatan lebih besar untuk belajar dari berbagai kemungkinan variasi gambar, sehingga menjadi lebih robust dalam mendeteksi klasifikasi kematangan sawit.

3.2 Transfer Learning

Transfer learning merupakan teknik dalam pembelajaran mesin yang memungkinkan model yang telah dilatih sebelumnya pada dataset besar digunakan kembali untuk menyelesaikan tugas-tugas baru dengan dataset yang lebih kecil atau berbeda. Teknik ini sangat berguna dalam bidang pengolahan citra karena model pretrained (pra-latih) telah mempelajari fitur-fitur umum dari dataset yang sangat beragam, sehingga dapat diaplikasikan pada masalah yang lebih spesifik tanpa harus memulai pelatihan model dari awal (scratch). Pada penelitian ini, transfer learning dipilih sebagai pendekatan utama untuk membangun model klasifikasi citra kelapa sawit matang dan belum matang.

Model yang digunakan dalam transfer learning adalah Xception dan VGG16. Kedua model ini telah dilatih sebelumnya pada dataset ImageNet, sebuah dataset besar yang berisi jutaan gambar dengan ribuan kategori. Dengan memanfaatkan model pretrained seperti Xception dan VGG16, proses ekstraksi fitur dari citra input menjadi lebih efisien karena fitur dasar seperti tepi, pola, dan tekstur sudah "dipelajari" oleh model. Dalam implementasinya, kedua model ini dimodifikasi pada bagian layer akhirnya (fully connected layer) agar sesuai dengan jumlah kelas pada dataset penelitian ini, yaitu dua kelas: kelapa sawit matang dan belum matang.

1. Xception

Xception (Extreme Inception) adalah model deep learning yang dikembangkan oleh François Chollet, yang didasarkan pada prinsip depthwise separable convolution. Model ini merupakan pengembangan dari arsitektur Inception, dengan fokus pada efisiensi dan performa yang lebih baik dalam mengekstraksi fitur dari citra. Xception sangat populer dalam tugas-tugas klasifikasi citra karena kemampuannya dalam menangani dataset dengan kompleksitas tinggi. Dalam penelitian ini, Xception digunakan untuk memanfaatkan kemampuannya dalam mengenali pola-pola yang relevan pada citra kelapa sawit. Selain itu, layer akhir dari model ini disesuaikan agar dapat memprediksi dua kategori, yaitu matang dan belum matang.²

2. VGG16

VGG16 adalah model convolutional neural network (CNN) yang dikembangkan oleh tim Visual Geometry Group dari Universitas Oxford. Model ini memiliki arsitektur sederhana dengan 16 lapisan, yang terdiri dari convolutional layers, pooling layers, dan fully connected layers. Keunggulan utama dari VGG16 adalah kemampuannya untuk menghasilkan representasi fitur yang kaya, meskipun memiliki arsitektur yang relatif sederhana dibandingkan dengan model modern lainnya. Dalam penelitian ini, VGG16 digunakan untuk mengekstraksi fitur dari citra kelapa sawit dengan mengganti layer fully connected terakhir untuk menyesuaikan output dengan jumlah kelas, yaitu matang dan belum matang.

3.3 Implementasi Transfer Learning

Proses transfer learning dalam penelitian ini dilakukan dengan memanfaatkan library populer dalam Python, seperti TensorFlow dan Keras. Langkah pertama adalah memuat model pretrained (Xception dan VGG16) tanpa termasuk layer terakhirnya, yang kemudian digantikan dengan layer fully connected baru. Layer baru ini terdiri dari beberapa lapisan dense dengan fungsi aktivasi softmax untuk mengklasifikasikan citra ke dalam dua kelas yang diinginkan. Selama proses pelatihan, parameter dari layer-layer pretrained dapat dibekukan (frozen) agar tidak diperbarui, atau sebagian dari parameter tersebut dapat disesuaikan (fine-tuned) untuk meningkatkan performa model pada dataset spesifik.

```
# Load VGG16 pre-trained model without the top layer (fully connected layers)
vgg16_base = VGG16(weights='imagenet', include_top=False, input_shape=(299, 299, 3))

# Load Xception pre-trained model without the top layer (fully connected layers)
xception_base = Xception(weights='imagenet', include_top=False, input_shape=(299, 299, 3))
```

Gambar 3. 4 Implementasi VGG16 dan Xception

Pada gambar 3.2 kode yang diberikan memuat dua model deep learning pre-trained, yaitu VGG16 dan Xception, tanpa lapisan fully connected di bagian atasnya. VGG16 adalah model CNN yang memiliki 16 lapisan dan telah dilatih sebelumnya pada dataset ImageNet. Dengan menggunakan opsi `include_top=False`, hanya lapisan konvolusi dan pooling yang dimuat, sementara lapisan fully connected dihilangkan. Model ini diharapkan menerima input gambar dengan ukuran 299x299 piksel dan 3 saluran warna (RGB). Begitu pula dengan model Xception, yang mengadopsi arsitektur yang lebih kompleks dengan menggunakan depthwise

separable convolutions. Model ini juga dimuat tanpa lapisan top dan diharapkan menerima input dengan ukuran yang sama, yaitu 299x299 piksel dengan 3 saluran warna. Keduanya memanfaatkan bobot yang telah dilatih pada dataset ImageNet, dan keduanya berfungsi untuk mengekstraksi fitur dari gambar yang diberikan, yang dapat digunakan untuk berbagai aplikasi lanjutan seperti klasifikasi atau deteksi objek.

Dengan menggunakan Xception dan VGG16, penelitian ini memanfaatkan keunggulan transfer learning untuk mengatasi tantangan dalam klasifikasi citra kelapa sawit. Pendekatan ini tidak hanya menghemat waktu dan sumber daya komputasi, tetapi juga meningkatkan akurasi dan generalisasi model karena fitur-fitur yang dipelajari dari dataset besar seperti ImageNet diaplikasikan pada dataset penelitian yang relatif kecil.

3.4 Hyperparameter Adam

Hyperparameter adalah tahap di mana berbagai kombinasi parameter diuji untuk mencari konfigurasi terbaik yang dapat meningkatkan akurasi model serta meminimalkan kemungkinan terjadinya overfitting. Pada penelitian ini, optimizer yang dipilih adalah Adam (Adaptive Moment Estimation), yang merupakan salah satu optimizer yang banyak digunakan dalam framework TensorFlow. Adam dipilih karena kemampuannya dalam mengoptimalkan parameter dengan cepat dan efisien melalui pendekatan berbasis momentum dan rata-rata eksponensial dari gradien. Untuk mengatur kecepatan pembelajaran, digunakan beberapa nilai learning rate yang berbeda, yaitu 0,1, 0,01, dan 0,001, dengan harapan untuk melihat pengaruhnya terhadap kinerja model. Model dilatih selama 20 epoch untuk memastikan bahwa model mendapatkan cukup iterasi untuk belajar dari data. Selain itu, fungsi aktivasi yang digunakan dalam model ini adalah softmax, yang umum digunakan untuk tugas klasifikasi, karena kemampuannya untuk mengubah output model menjadi probabilitas yang dapat diinterpretasikan. Untuk mencegah overfitting lebih lanjut, diterapkan layer dropout dengan berbagai nilai rate, yaitu 0,1, 0,01, dan 0,001, yang bertujuan untuk secara acak menonaktifkan sejumlah unit selama proses pelatihan dan dengan demikian mendorong model untuk belajar representasi yang lebih robust dan generalis. Semua pengaturan hyperparameter ini dijelaskan lebih lanjut pada Tabel 3.1.

| No | Pembagian Data | Learning Rate | Dropout |
|-----|----------------|---------------|---------|
| 1. | 90:10 | 0,1 | 0,1 |
| 2. | | 0,1 | 0,01 |
| 3. | | 0,01 | 0,1 |
| 4. | | 0,01 | 0,01 |
| 5. | 80:20 | 0,1 | 0,1 |
| 6. | | 0,1 | 0,01 |
| 7. | | 0,01 | 0,1 |
| 8. | | 0,01 | 0,01 |
| 9. | 70:30 | 0,1 | 0,1 |
| 10. | | 0,1 | 0,01 |
| 11. | | 0,01 | 0,1 |
| 12. | | 0,01 | 0,01 |

Tabel 3. 1 Skema yang Digunakan untuk Pelatihan Model

3.5 Confusion Matrix

Pada tahap evaluasi, penilaian kinerja model dilakukan dengan menggunakan confusion matrix yang menghasilkan metrik-metrik evaluasi penting seperti akurasi, recall, presisi, dan F1 score. Confusion matrix adalah alat yang sangat berguna dalam menganalisis hasil klasifikasi karena memberikan gambaran yang jelas tentang jumlah prediksi yang benar dan salah untuk setiap kelas. Dengan demikian, metrik-metrik ini membantu untuk mengevaluasi seberapa baik model dalam mengklasifikasikan kematangan buah sawit. Akurasi mengukur seberapa sering model memberikan prediksi yang benar, sementara recall menunjukkan sejauh mana model dapat menemukan semua contoh yang relevan dari kelas yang bersangkutan. Presisi mengukur seberapa akurat prediksi positif yang diberikan oleh model, dan F1 score merupakan rata-rata harmonis dari recall dan presisi, yang memberikan gambaran keseimbangan antara keduanya. Evaluasi ini bertujuan untuk mengukur kinerja algoritma secara menyeluruh dan juga untuk menilai pengaruh augmentasi data terhadap hasil yang diperoleh.

Selain itu, evaluasi juga dilakukan dengan membandingkan hasil model yang menggunakan augmentasi data dengan model yang tidak menggunakan augmentasi. Augmentasi data dapat membantu meningkatkan kinerja model, terutama ketika jumlah data terbatas, dengan memberikan variasi tambahan pada data latih yang dapat memperkaya fitur yang dipelajari oleh model. Pada evaluasi ini, data dibagi menjadi tiga proporsi yang berbeda untuk latih dan validasi, yaitu (90:10), (80:20), dan (70:30), yang memungkinkan untuk menguji sejauh mana pembagian data mempengaruhi kemampuan model dalam generalisasi dan akurasi prediksi. Pembagian data yang berbeda ini memberikan kesempatan untuk melihat bagaimana model beradaptasi dengan jumlah data latih yang beragam. Hasil dari confusion matrix yang digunakan untuk mengukur kinerja model pada klasifikasi kematangan sawit dapat dilihat lebih lanjut pada Tabel 3.2., yang merinci setiap metrik evaluasi secara rinci.

| Kelas Benar | Sawit Matang | Belum Matang |
|--------------|---------------|----------------|
| Sawit Matang | True Positive | False Positive |
| Sawit Mentah | True Negative | False Negative |

Tabel 3. 2 Confusion Matrix Kematangan Sawit

Confusion matrix menunjukkan hasil klasifikasi dengan kategori-kategori sebagai berikut:

- True Positive (TP) adalah citra sawit yang seharusnya negatif namun diprediksi sebagai positif.
- True Negative (TN) adalah citra sawit yang seharusnya positif namun diprediksi sebagai negatif.
- False Positive (FP) adalah citra sawit yang seharusnya negatif namun diprediksi sebagai positif.
- False Negative (FN) adalah citra sawit yang seharusnya positif namun diprediksi sebagai negatif.

Menurut (Verdy and Ery Hartati 2024) Confusion matrik terdiri 4 fitur matrik yang terdiri dari sebagai berikut:

Berikut adalah konversi rumus ke dalam format LaTeX:

a. Akurasi

$$\text{Akurasi} = \frac{(TP + TN)}{(TP + TN + FP + FN)}$$

b. Presisi

$$\text{Presisi} = \frac{TP}{(TP + FP)}$$

c. Recall

$$\text{Recall} = \frac{TP}{(TP + FN)}$$

d. F1 Score

$$\text{F1 Score} = \frac{(\text{precision} \times \text{recall})}{(\text{precision} + \text{recall})}$$

Refrensi

- Akbar, Arief Rahmad Maulana, Alan Dwi Wibowo, and Redi Santoso. 2023. "Investigation on the Optimal Harvesting Time of Oil Palm Fruit." *Jurnal Teknik Pertanian Lampung (Journal of Agricultural Engineering)* 12(2): 524. doi:10.23960/jtep-1.v12i2.524-532.
- Avery, Katherine R., Jwo Pan, Carlos Carvalho Engler-Pinto, Zhigang Wei, Fulun Yang, Shengbin Lin, Limin Luo, and Dmitri Konson. 2014. "Fatigue Behavior of Stainless Steel Sheet Specimens at Extremely High Temperatures." *SAE International Journal of Materials and Manufacturing* 7(3): 560–66. doi:10.4271/2014-01-0975.
- Carnegie, Jeremy Onesimus, Aditya Rio Prabowo, Eko Prasetya Budiana, and Ivan Kristianto Singgih. 2022. "Essential Oil Plants Image Classification Using Xception Model." *Procedia Computer Science* 204: 395–402. doi:10.1016/j.procs.2022.08.048.
- Chan Uswatun, Angkin, Farrel. 2023. "Implementasi Data Augmentation Random Erasing Dan GridMask Pada CNN Untuk Klasifikasi Batik." *Jurnal Sisfoteknika* 13(1): 16–28.
- Fevriera, Sotya, and Fhrista Safara Devi. 2023. "Analisis Produksi Kelapa Sawit Indonesia: Pendekatan Mikro Dan Makro Ekonomi." *Transformatif* XII(1): 1–16.
- Hassan, Muneeb ul. 2018. "VGG16 – Convolutional Network for Classification and Detection." <https://neurohive.io/en/popular-networks/vgg16/>.
- Indonesia, Bps-statistics. 2024. "Statistik Kelapa Sawit Indonesia 2023." 17.
- Masaugi, Fathan Fanrita. 2024. "Deep Learning Menggunakan Algoritma Xception Dan Augmentasi Flip Pada Klasifikasi Kematangan Sawit." *KLIK: Kajian Ilmiah Informatika dan Komputer* 6(4): 2918–27. doi:10.30865/klik.v4i6.1938.
- Murgianto, Fitrah, Edyson Edyson, Adhy Ardiyanto, Shadiar Kesuma Putra, and Lilik Prabowo. 2021. "Potential Content of Palm Oil at Various Levels of Loose Fruit in Oil Palm Circle." *Jurnal Agro Industri Perkebunan* (October): 91–98. doi:10.25181/jaip.v9i2.2161.
- Rizki, Fachrul, Muhammad Pajar Kharisma Putra, Maulana Aziz Assuja, and Fenty Ariany. 2023. "Implementasi Deep Learning Lenet Dengan Augmentasi Data Pada Identifikasi Anggrek." *Jurnal Informatika dan Rekayasa Perangkat Lunak* 4(3): 357–66. doi:10.33365/jatika.v4i3.3652.
- Siswanto, Yudi, Zulkarnain Lubis, and Erwin Nyak Akoeb. 2020. "Analisis Faktor-Faktor Yang Mempengaruhi Produksi Kelapa Sawit Rakyat Di Desa Tebing Linggahara Kecamatan Bilah Barat Kabupaten Labuhanbatu." *AGRISAINS: Jurnal Ilmiah Magister Agribisnis* 2(1): 60–70. doi:10.31289/agrisains.v2i1.255.
- Thakur, Rohit. 2024. "Beginner's Guide to VGG16 Implementation in Keras." <https://builtin.com/machine-learning/vgg16>.
- Verdy, and Ery Hartati. 2024. "Klasifikasi Penyakit Mata Menggunakan Convolutional Neural Network Model Resnet-50." *Jurnal Rekayasa Sistem Informasi dan Teknologi* 1(3): 199–206. doi:10.59407/jrsit.v1i3.529.